

ENTREPÔTS DE DONNEES (Datawarehouse)

Dr. Cheikh Tidiane DIENG

Université Gaston Berger de Saint-Louis

UFR des Sciences Appliquées et Technologie

Section Informatique

cheikh-tidiane.dieng@ugb.edu.sn

Chapitre 3: Extract-Transform-Load (ETL)

- Extraction – Transformation - Chargement

Formats variés différents

- Les données de l'entreprise sont stockées dans des systèmes transactionnels qui enregistrent les données de manières **quotidiennes** et en **continu**.
- **Différentes sources de données et différents formats :**
 - Fichiers Excel....
 - ERPs
 - Systèmes de CRMs
 - Capteurs
 - SGBD Relationnels
- **Et aujourd'hui :**
 - Données du Web
 - Twitter
 - Facebook
 - Whatsapp
 - ...

Langage et protocole différents

- Interfaces d'accès variées en termes de:
 - Modèle de données: relationnel, Objet, XML, HTML, tableurs
 - Langages d'interrogation: SQL, SQL3, XPath, XQuery, URL, ...
 - Protocoles de communication: JDBC, ODBC, SOAP, HTTP


Globalisation des données



Globalisation des données et des ressources

C'est quoi l'intégration ?

Illusion d'un Système unique et homogène



Problématique (1)

1. Enumérer les sources cibles nécessaires à l'**alimentation** de l'ED (DW).
2. Pour chaque source cible, trouver la **partie qui nous intéresse**.
3. Si plusieurs sources sont trouvées, choisir la plus **pertinente**.
4. Si la source cible exige des données de plusieurs autres sources, former des règles de **consolidation**.
5. Inspecter les sources pour détecter d'éventuelles **valeurs manquantes, des valeurs aberrantes, des valeurs extrêmes**, etc.
 - Test de normalité.
6. Tenir compte de la **puissance** des **sources** et de leur **charge**.
7. Les sources peuvent être **temporairement indisponibles**.

Problématique (2)

L'hétérogénéité concerne aussi bien les **données**, les **modèles** mais aussi les **langages**.

- **Système homogène :**

- même logiciel gérant les données sur tous les sites
- même modèle de données
- même univers de discours

- **Système hétérogène :**

- n'adhère pas à toutes les caractéristiques d'un système homogène
- langages de programmation et d'interrogation différents, modèles différents, SGBD différents

Hétérogénéité sémantique


- Signification, interprétation ou utilisation différente de la même donnée
- Types de relations sémantiques
 - R1 identique à R2 : même constructeur, même concept
 - R1 équivalente à R2 : constructeurs différents, même concept
 - R1 compatible avec R2 : ni identiques, ni équivalents
 - R1 incompatible avec R2 : contradictoires

Hétérogénéité structurelle

- **Structurelle**

- Représentation différente des mêmes concepts dans des bases différentes
 - Conflits de noms, types de données, attributs, unités ...

Localisation des données (1)



Localisation des données (2)

- **Intégration matérialisée**

- Les données provenant des sources à intégrer sont stockées sur un support spécifique (entrepôt de données).
- L'interrogation s'effectue comme sur une BD classique (relationnelle).

- **Intégration virtuelle**

- Les données restent dans les sources
- Les requêtes sont faites sur un schéma global, puis décomposées en sous-requêtes sur les sources. Les différents résultats des sources sont combinés pour former le résultat final.

Représentation des aspects sémantiques

- Logique de description
 - Méta-attributs et valeurs à représentation d'un contexte
 - Dictionnaires de données à vocabulaire utilisé dans les bases de données
 - Ontologies décrivant des domaines de discours (concepts, relations, valeurs)

Matérialisé vs Virtuel


- **Architectures matérialisées**

- Bonnes performances
- Données pas toujours fraîches
- Nettoyage et filtrage des données


- **Architectures virtuelles**

- Les données sont toujours fraîches
- Traitement de requêtes peut être coûteux
- Défi principal : performances

Architecture d'entrepôt de données




Architecture de médiateur




Intégration de données

L'intégration de données appelé ETL (Extraction Transfer Loading) regroupe les processus par lesquels les données provenant de différentes parties du système d'information sont déplacées, combinées et consolidées. Ces processus consistent habituellement à extraire des données de différentes sources (bases de données, fichiers, applications, Services Web, emails, etc.), à leur appliquer des transformations (jointures, lookups, déduplication, calculs, etc.), et à envoyer les données résultantes vers les systèmes cibles.

- Source : [wikiversity.org](https://www.wikiversity.org)





Chargement des données

- Le chargement des données peut se faire de trois façons différentes :
 - **Push** : la logique de chargement est dans le système de production, il pousse les données vers la zone de préparation (**Staging Area**) quand il en a l'occasion.
 - **Pull** : les données sont tirées de la source vers le Staging Area.
 - **Push-Pull** : La source prépare les données à envoyer et prévient le Staging Area qu'elle est prête. Le Staging Area va récupérer les données.
 - Si la source est occupée, le Staging Area fera une autre demande plus tard.

Méthodes de rafraichissement des données


Trois types d'extraction de données :

- **Rafraichissement complet :**
 - Capture de l'ensemble des données disponibles
 - Pour le chargement initial, ou rafraichissement de données
- **Rafraichissement incrémentale :**
 - Chargement des nouvelles données (seulement)
- **Rafraichissement Temps-réel :**
 - S'exécute au moment où les transactions surviennent dans les systèmes sources

Intégration de données

- Objectif général : utiliser plusieurs sources comme si elles constituaient une seule base de données homogène **l'intégration de données** doit fournir
 - **un accès** (requêtes, éventuellement mises-à-jour)
 - **uniforme** (comme si c'était une seule BD homogène)
 - **à des sources** (pas seulement des BD)
 - **multiples** (déjà deux est un problème)
 - **autonomes** (sans affecter leur comportement, indépendant des autres sources ou du système d'intégration)
 - **hétérogènes** (différents modèles de données, schémas)
 - **structurées** (ou semi-structurées)

Exemple



Quelques applications de l'intégration de données

- ***Dans l'entreprise : « business integration »***
 - Accès efficace, facile et sûr à des données internes et externes à l'entreprise
 - Données: BD locales, textes lois/contrats, applications CRM, eProcurement, ...
 - Une partie très importante des budgets IT sont dépensés en intégration
- ***Communautés web***
 - Partage d'information produites par divers acteurs
 - Portail d'accès uniforme
 - Exemple: recherche biomédicale
- ***Grand public***
 - Accès simple, rapide et efficace aux informations disponibles sur le web
 - Texte/HTML, images, vidéo, XML, fils RSS, cartes
 - Le web caché, services web
 - Commerce électronique: comparateurs de prix, intégration de magasins en ligne
 - Réservation de billet d'avion (proposition de chambre d'hôtel, de taxi, etc.)

Caractéristiques de l'intégration de données

- ***Distribution***

- Répartition géographique des sources sur le réseau
- Échelle

- ***Autonomie***

- Les sources décident de ce qu'elles partagent, comment et quand


- ***Hétérogénéité***

- De format, de structure, de mode d'accès, de capacité de traitement


Intégration matérialisée et virtuelle

- Intégration matérialisée ***entrepôt de données***
 - Les données provenant des sources sont transformées et stockées sur un support spécifique (entrepôt de données).
 - L'interrogation s'effectue comme sur une BD classique
- Intégration virtuelle ***médiateur***
 - Les données restent dans les sources
 - Les requêtes sont exprimées sur le schéma global, puis décomposées en sous-requêtes sur les sources
 - Les résultats des sources sont combinés pour former le résultat final
- En pratique on peut avoir des architectures intermédiaires, entre ces deux extrêmes


Architecture générale d'intégration



Architecture d'entrepôt



Architecture de médiation




Entrepôt ou Médiateur ?

- **Médiateur** : accès direct aux sources
 - approche « paresseuse », pas de matérialisation
 - migration de requêtes vers les sources
 - *avantages* : données toujours fraîches, plus facile d'ajouter de nouvelles sources, plus grande échelle, distribution de l'effort
 - *inconvénients* : performances, traduction de requêtes, capacités différentes des sources
- **Entrepôt de données** : accès efficace à une copie des données
 - matérialisation des sources au niveau du modèle global
 - migration de données vers l'entrepôt
 - *avantages* : performances, personnalisation des données (nettoyage, filtrage), versions
 - *inconvénients* : données pas toujours fraîches, cohérence, gestion des mises-à-jour, gestion de gros volumes de données

Entrepôt de données

- L'approche la plus populaire d'intégration de données
 - Gros avantages: performances, contrôle plus facile à réaliser sur l'hétérogénéité des données
- Utilisation pour les systèmes décisionnels OLAP
- Transformation de données pour alimenter l'entrepôt:
 - Chargeurs = *systèmes ETL* (« *Extract, Transform, Load* »)
 - Outils graphiques pour définir *des flots de traitements/transformation*s
 - Une fois le flot de traitement défini appliqué au contenu des sources

Exemple de logiciel d'ETL: Talend



Médiateur

- Bien que moins utilisés en pratique, ils ont plus de potentiel:
 - Meilleur passage à l'échelle
 - Acceptent mieux les changements dynamiques (nouvelles sources) mieux adaptés à l'intégration de sources web
- En entreprise: EII « Enterprise Information Integration »
 - Exemple de logiciels mediateurs : BEA Liquid Data, IBM Websphere, Information Integrator

Décomposition des requêtes

- Exemple : chercher l'adresse de tous les propriétaires de voiture verte




Schéma d'intégration

- Problèmes
 - *Intégration de schéma*: comment définir un schéma global d'intégration à partir des schémas des sources?
 - *Fusion de données*: comment rendre compatibles, transformer les données en provenance des sources?
 - *Mappings/vue d'intégration*: comment décrire le lien entre le schéma global et les schémas des sources?

Définition de la vue d'intégration

Le lien entre schéma global et schémas locaux est défini à travers des vues en faisant un Mapping entre ces schémas. Il existe deux façons principales de définir ce lien:


- Le schéma global en fonction des schémas locaux « ***global as view*** »
 - Approche *ascendante*: on part des sources pour produire le schéma global
- Les schémas locaux en fonction du schéma global « ***local as view*** »
 - Approche *descendante*: on fixe le schéma global et on décrit les sources par rapport à ce schéma fixé

Global As View

- Le modèle global = vue sur les sources
 - élément global = $f(\text{éléments des sources})$

$$\mathbf{SG} = \mathbf{V}(\mathbf{S1}, \dots, \mathbf{Sn})$$

- Avantages
 - approche naturelle
 - Pas de traduction de requetes
- **Inconvénients**
 - une nouvelle source entraine la modification du modèle global
 - il faut considérer l'interaction de la nouvelle source avec les autres



Global As View

- Conception facile
- Possibilité de construire des hiérarchies de schémas de médiation
- Risque de perdre de l'information
- L'ajout de sources est difficile, et demande de prendre en compte l'ensemble des sources disponibles. Passe mal à l'échelle.

Global As View

- *Quelles sont les critiques des films réalisés par W. Allen ?*

SELECT Films.titre, Critiques.critique

FROM Films, Articles

WHERE Films.Realisateur = 'W. Allen' AND Films.titre=Articles.titre;

Global As View

- *Quelles sont les critiques des films réalisés par W. Allen ?*

SELECT Films.titre, Critiques.critique

FROM Films, Articles

WHERE Films.Realisateur = 'W. Allen' AND Films.titre=Articles.titre

Local As View

- Les sources = vues matérialisées du modèle global
 - une source décrit les données du modèle global qu'elle peut fournir
 - élément source = $f(\text{éléments modèle global})$

Si inclus dans $V_i(M)$

- **Avantages**
 - les sources sont décrites indépendamment les unes des autres
 - très simple de rajouter une nouvelle source

Local As View

- Les sources = vues matérialisées du modèle global
 - une source décrit les données du modèle global qu'elle peut fournir
 - élément source = $f(\text{éléments modèle global})$

Si inclus dans $V_i(M)$

- **Avantages**
 - les sources sont décrites indépendamment les unes des autres
 - très simple de rajouter une nouvelle source
- **Inconvénients**
 - traduction de requêtes plus complexes

Local As View

Modèle global du médiateur LAV:

–M: Film(titre, année, genre, réalisateur),
Acteur(nom, titre)

- Sources de données :

- S1: titre, années et réalisateurs de comédies
- S2: acteurs avec le titre et année des films où ils ont joué
- S3: réalisateurs, titres des films et acteurs qui y jouent
- S4: titre et genre de films français d'avant 1970

Local As View

Modèle global du médiateur LAV:

–M: Film(titre, année, genre, réalisateur), Acteur(nom, titre)

- Sources de données :

–S1: titre, années et réalisateurs de comédies

–S2: acteurs avec le titre et année des films où ils ont joué

–S3: réalisateurs, titres des films et acteurs qui y jouent


–S4: titre et genre de films français d'avant 1970

– $S1(t, a, r) \subseteq M:Film(t, a, "comédie", r)$

– $S2(n, t, a) \subseteq M:Acteur(n, \underline{t}) M:Film(\underline{t}, a, g, r)$


– $S3(r, t, n) \subseteq M:Film(\underline{t}, a, g, r) M:Acteur(n, \underline{t})$

– $S4(t, g) \subseteq M:Film(t, a, g, r), a < 1970$



Films(Fid, titre, realisateur, année, genre)
Affiche(cinema, titre, horaire)
Articles(titre, critique)

Cine as
SELECT cinema, genre
From Films F, Affiche A
Where F.Titre = A.Titre



Cine(cinema, genre)

Quelles sont les critiques des comédies depuis 1950 ?

```
SELECT Films.titre, Critiques.article  
FROM Film, Critiques  
WHERE Film.Fid=Critiques.Fid AND Film.genre='comédie' AND  
       Film.annee >=1950
```

Traduction de la requête :

```
SELECT S1.Film.titre, S3.Critiques.article  
FROM S1.Film, S3.Critiques  
WHERE S1.Film.Fid=S3.Critiques.Fid
```

Pb: la requête reformulée n'est pas équivalente à la requête originale, car elle renvoie seulement les critiques des films depuis 1990.

Problème d'incomplétude des réponses !

Système Local As View

- Information Manifold (AT&T)
 - modèle global : de type entité – association, exprimé par des relations