

Plan du cours

- Introduction
 - Définitions et Motivations
 - Le processus d' extraction de connaissances
 - Les techniques de data mining
- Règles d' associations
 - Cas transactionnel
 - Optimisations et extensions
- Classification
- Clustering

Bibliographie

- Data Warehousing, Data Mining & OLAP – A. Berson, S. J. Smith – McGraw-Hill
- Data Mining Techniques for Marketing, Sales and Customer Support – M. J.A.Berry, G. Linoff – Wiley
- Data Mining: Concepts and Techniques – J. Han, M. Kamber - Morgan Kaufmann Publishers
- Advances in Knowledge Discovery and Data Mining - V. Fayyad, P-Shapiro, Uthurasamy – MIT Press
- Data Mining - Lefébure & Venturi. Eyrolles
- Data Mining: practical machine learning tools and techniques with Java Implementations - Witten & Frank. Morgan Kaufmann Publishers

Définitions

- Le data mining est l'ensemble
 - Des algorithmes et méthodes
 - destinés à l'exploration et à l'analyse de grandes bases de données informatiques
 - Permettant de détecter dans les données
 - des règles, des associations, des tendances inconnues, des structures particulières
 - restituant l'information utile
 - tout en réduisant la quantité de données
 - **Pour l'aide à la décision**

Définitions

- Processus non trivial d'identification d'informations *valides, nouvelles, potentiellement utiles et compréhensibles* à partir de *grandes masses de données*
- Processus de découverte de corrélations, formes, régularités et tendances nouvelles et significatives en passant au crible de grandes quantités de données et en utilisant des technologies d'apprentissage et d'IA, conjointement aux techniques statistiques et mathématiques
- Vocabulaire : Fouille de données, Extraction de connaissances (ECD), KDD

Data Mining : Motivation

- De plus en plus de données sont collectées
 - Données du web, e-commerce
 - Achats dans les grandes surfaces
 - Transactions bancaires (cartes de crédit)
- Ordinateurs plus puissants et moins chers
 - Puissants processeurs, beaucoup de mémoire
- La compétition est rude
 - Nécessité pour une entreprise de bien connaître ses clients
 - Gestion de la relation Client, CRM

Data Mining : Motivation

Besoin d'explorer :

- données courantes de l'entreprise
 - + données historisées
- à des fins d'aide à la décision

Pbme: données trop importantes

⇒ nouvelles techniques + efficaces;

⇒ nouveaux outils intelligents

...d'analyse, de compréhension et d'exploration
des données

Ce que l' on veut savoir

- On ne veut plus seulement savoir
 - Combien de clients ont acheté tel produit pendant telle période?
- Mais
 - Quel est leur profil?
 - Quels autres produits les intéresseront?
 - Quand seront-ils intéressés?

Des statistiques ...

- Statistiques
 - Quelques centaines d'individus
 - Quelques variables recueillies avec un protocole spécial (échantillonnage, ...)
 - Fortes hypothèses (a priori) sur les lois statistiques suivies
- Analyse de données
 - Quelques dizaines de milliers d'individus
 - Quelques dizaines de variables
 - Construction de tableaux Individus x Variables
 - Importance de la représentation visuelle

... au Data Mining

- Contexte actuel
 - Quelques dizaines de millions d'individus
 - Quelques centaines de variables
 - Variables numériques ou symboliques
 - Données recueillies souvent avant l'étude et à d'autres fins
 - Données imparfaites avec des erreurs de codification
 - Nécessité de calculs rapides
- Nouvel objectif
 - On ne cherche pas toujours l'optimum mathématique
 - Mais le modèle le plus **facile à appréhender** par un utilisateur **non statisticien**

Utilisation du Data Mining

- Sondage sur « www.kdnuggets.com »
 - Fields where you currently apply data mining (608 votes)

• <i>Banking</i>	<i>13%</i>	<i>Insurance</i>	<i>6%</i>
• <i>Biology / Genetic</i>	<i>5%</i>	<i>Direct Marketing</i>	<i>7%</i>
• <i>E-commerce / Web</i>	<i>9%</i>	<i>Entertainment</i>	<i>2%</i>
• <i>Fraud Detection</i>	<i>8%</i>	<i>Investments / Stocks</i>	<i>3%</i>
• <i>Manufacturing</i>	<i>3%</i>	<i>Pharmaceuticals</i>	<i>5%</i>
• <i>Retail</i>	<i>6%</i>	<i>Scientific Data</i>	<i>8%</i>
• <i>Security</i>	<i>2%</i>	<i>Supply Chain Analysis</i>	<i>3%</i>
• <i>Telecommunications</i>	<i>9%</i>	<i>Others</i>	<i>7%</i>


Applications du Data mining

- Analyse du panier de la ménagère dans les grandes surfaces (pour déterminer les produits souvent achetés simultanément, et agencer les rayons et organiser les promotions en conséquence)
- Etudes d'appétence dans les sociétés commerciales (pour concentrer le mailing et le phoning sur les clients les plus susceptibles de répondre favorablement)
 - Appétence : tendance de tout être vers ce qui peut satisfaire ses instincts et ses besoins, surtout physiques.
- Prédiction de l'attrition (c'est à dire du départ d'un client pour un concurrent) dans la téléphonie mobile, dans l'assurance (produits obligatoires)

Applications du Data mining

- Exemples médicaux
 - Déterminer des segments de patients susceptibles d'être soumis à des protocoles thérapeutiques déterminés, chaque segment regroupant tous les patients réagissant identiquement
 - Prédire le temps de rétablissement après une opération, en fonction des données concernant le patient (age, poids, taille, fumeur, métier, antécédents médicaux, etc) et le praticien (nb d'opérations pratiquées, nb d'années d'expérience,...)

Data mining comme étape du processus de découverte de connaissances



Découverte de connaissances

- Nettoyage des données
 - Objectif
 - Supprimer les données bruitées ou non pertinentes
 - Questions posées
 - Que faire si certaines données sont manquantes?
 - Les données sont –elles fiables?
 - Que faire si données inconsistantes?

Nettoyage des données

- Traitements possibles si données manquantes
 - Ne pas tenir compte des tuples contenant des données manquantes
 - Remplir manuellement les champs non remplis
 - Utiliser les valeurs connues
 - En remplaçant par exemple un salaire manquant par le salaire médian d'un client
 - Pour prédire les valeurs manquantes, par exemple le salaire d'un client en fonction de son âge et de sa profession

Nettoyage des données

- Traitements possibles si données bruitées
 - Par des techniques de lissage (data smoothing)
 - Trier les différentes valeurs de l'attribut considéré
 - 4, 8, 15, 21, 21, 24, 25, 28, 34
 - Partitionner l'ensemble résultat (ex : en paquets de trois)
 - 4, 8, 15 // 21, 21, 24 // 25, 28, 34
 - Remplacer les valeurs initiales par de nouvelles valeurs en fonction du partitionnement réalisé
 - Par la valeur moyenne des regroupements réalisés (9, 22, 29)
 - Par les min et max des regroupements réalisés (4, 4, 15 // 21, 21, 24 // 25, 25, 34)
 - Implique une perte de précision ou d'information

Nettoyage des données

- Autres traitements possibles si données bruitées
 - Par des techniques de clustering (segmentation)
 - Des valeurs similaires seront placées dans une même classe
 - On ne tiendra pas compte des valeurs isolées (outliers)
 - Une valeur sera dite isolée si elle se retrouve dans une classe comportant trop peu d'éléments
 - Par des techniques de régression linéaire
 - Dans le cas où un attribut Y dépend linéairement d'un attribut X
 - Années d'expériences X et salaire Y
 - Trouver les coefficients « a » et « b » satisfaisant au mieux la relation $Y = a + b.X$
 - Remplacer les valeurs données de Y par celles prédites

Nettoyage des données

- Régression linéaire
 - Données de départ
 - Un ensemble de couples (X_i, Y_i)
 - Calcul des coefficients
 - Soit $E(X)$ et $E(Y)$ les valeurs moyennes des attributs X et Y
 - $b = \sum (X_i - E(X))(Y_i - E(Y)) / \sum (X_i - E(X))^2$
 - $a = E(Y) - b.E(X)$
 - Exemple
 - $X : \quad 3 \quad 8 \quad 9 \quad 13 \quad 3 \quad 6 \quad 11 \quad 21 \quad 1 \quad 16$
 - $Y : \quad 30 \quad 57 \quad 64 \quad 72 \quad 36 \quad 43 \quad 59 \quad 90 \quad 20 \quad 83$
 - $E(X) = 9.1$ et $E(Y) = 55.4$
 - $b = 3.7$ et $a = 21.7$
 - Si $X_i = 10$, on doit avoir $Y_i = 58.7$

Nettoyage des données

- Si données inconsistantes
 - Dans le cas des bases de données
 - Correspondent souvent à des contraintes d'intégrité non respectées
 - Certaines peuvent être corrigées manuellement
 - Utilisation d'outils d'ingénierie de connaissances pour détecter la violation de contraintes connues

Intégration

- Objectif
 - Regrouper des données provenant de plusieurs sources
 - Problématique typique lors de la construction des entrepôts
 - Exemple
 - Un attribut peut avoir différents noms dans différentes bases de données. Ex : C_ID dans bd1 et CUST_ID dans bd2
 - Utilisation de méta-données pour la mise en correspondance

Intégration

- BDs Traditionnelles
 - Données courantes manipulées par applications de production
 - Bases de données réparties sur des sites géographiquement éloignés
 - Systèmes et plateformes hétérogènes
- **Pas de vision globale et synthétique des activités de l'entreprise !!!**
- **⇒ Nécessité d'*INTEGRER* les données à des fins d'aide à la décision...**

Intégration

- Nécessité de l'Intégration
 - Vue globale des activités de l'entreprise
 - Existence de sources de données multiples et autonomes
 - Données sur plateformes hétérogènes
 - Formats distincts
 - Géographiquement éloignés
 - Besoin des données courantes + données historisées
 - $\Rightarrow$ Grands volumes de données
- Concept de DATAWAREHOUSE
(entrepôt de données)

Data Mining vs OLAP

- Analyse OLAP
 - Objectif : fournir à l'utilisateur une vue multidimensionnelle
 - S'effectue sur un cube de données : forme de représentation du modèle dimensionnel, les axes – dimensions, contenu – mesure
 - Ex : axes : temps, produit, localisation, mesure : ventes

- OLAP vs Data Mining

OLAP : rétrospection

1. Quels étaient mes 10 meilleurs clients l'année dernière ?
2. Quel était le montant des ventes par région le trimestre dernier

Data Mining : prédiction

1. Quels sont les 10 clients qui m'offriront potentiellement le plus de profit ?
2. Quelles sont les ventes attendues au trimestre prochain

Transformation des données

- Lissage des données (pour enlever le bruit)
 - Via des techniques de régression
- Normalisation des données
 - Normaliser les attributs numériques afin qu'ils varient entre 0 et 1.
 - Pour ne pas privilégier les attributs ayant les plus grands domaines de variation (ex : salaire par rapport à age)
- Agrégation des données
 - Opération OLAP classique dans les cubes de données
 - Calculer les niveaux de vente réalisées de tel produit par mois plutôt que par jour
- Généralisation des données
 - Remplacer les données fines par des données de plus haut niveau
 - Remplacer les adresses précises de clients par leur code postal
 - Remplacer l'age des clients par « young, middle-age, senior »

Sélection de données

- Objectifs
 - Garder uniquement les données pertinentes pour l'étude à réaliser
- Exemples de questions posées
 - Doit-on s'intéresser à toutes les catégories de produits?
 - Doit-on s'intéresser aux ventes réalisées il y a plus d'un an?

Réduction de données

- En ligne ou en colonne
 - En ligne : par échantillonnage
 - Pour des raisons de performances
 - Du fait de la complexité importante des algorithmes d'extraction
 - Méthode : échantillonnage aléatoire (avec ou sans remise), échantillonnage par clustering
- En colonne : par suppression des attributs redondants
 - Cas triviaux
 - Ex : l'âge d'un individu peut être déduit de sa date de naissance
 - Via une analyse des corrélations entre attributs
 - $\text{corr}_{A,B} = P(A \text{ et } B) / P(A) \cdot P(B) = P(B / A) / P(B)$
 - Indépendance si $\text{corr}_{A,B} = 1 : P(B / A) = P(B)$
 - Corrélation positive si $\text{corr}_{A,B} > 1 : P(B / A) > P(B)$
 - Corrélation négative si $\text{corr}_{A,B} < 1 : P(B / A) < P(B)$

Matrice de contingence

	Avec pain	Sans Pain	Total
Avec Beurre	4000	3500	7500
Sans Beurre	2000	500	2500
Total	6000	4000	10000

- Analyse de corrélation
 - $P(\text{Beurre}) = 7500/10000 = 0.75$ et $P(\text{Pain}) = 0.6$
 - $P(\text{Beurre et Pain}) = 4000 / 10000 = 0.4$
 - $\text{corr}_{\text{Pain, Beurre}} = 0.4 / (0.75 * 0.6) = 0.89 < 1$
 - Indique une corrélation négative
 - $P(\text{Beurre} / \text{Pain}) = 2/3 < 3/4 = P(\text{Beurre})$
 - $P(\text{Pain} / \text{Beurre}) = 0.53 < 0.6 = P(\text{Pain})$

Les techniques de data mining

- Les techniques descriptives
 - Visent à **mettre en évidence des informations présentes** mais cachées par le volume de données (c' est le cas des segmentations de clientèle et des recherches d' association de produits sur les tickets de caisse)
 - Réduisent, résument, synthétisent les données
 - Il n' y a pas de variable « cible » à prédire
- Les techniques prédictives
 - Visent à **extrapoler de nouvelles informations** à partir des informations présentes
 - Expliquent les données
 - Il y a une variable cible à prédire

Les techniques de data mining

- Classification [Predictive]
- Clustering [Descriptive]
- Association Rule Discovery [Descriptive]
- Sequential Pattern Discovery [Descriptive]
- Regression [Predictive]
- Deviation Detection [Predictive]

Classification : définition

- Etant donné un ensemble d'exemples (*training set*)
 - Chaque exemple contient un ensemble d'attributs, dont un est *la classe*
- Trouver *un modèle* pour la classe comme fonction des valeurs des autres attributs
- But : classer avec une certaine précision les nouveaux exemples (non encore vus)
 - Un *ensemble de test* est utilisé pour déterminer la précision du modèle
 - Ensemble d'essai pour construire le modèle, ensemble test pour le valider

Classification : Application 1

- Marketing direct
 - But : Réduire le coût du mailing en ciblant un ensemble de consommateurs susceptibles d'acheter un nouveau téléphone portable
 - Approche :
 - Utiliser les données d'un produit similaire déjà vendu
 - On sait quels clients ont décidé d'acheter ou pas $\Rightarrow$ classe
 - Recueillir différentes données sur ces clients : données démographiques, type de business, combien gagne le client,...
 - Utiliser cette information comme attributs pour trouver un modèle de classification

Classification : Application 2

- Détection de fraudes
 - But : Prévoir des cas de fraudes dans des transactions de cartes bancaires
 - Approche :
 - Utiliser les transactions sur les cartes de crédit et les informations sur le propriétaire du compte comme attributs
 - Quand il fait ses achats, ce qu' il achète,...
 - Marquer les transactions passées comme frauduleuses ou normales $\Rightarrow$ classe
 - Apprendre un modèle pour la classe de transactions
 - Utiliser ce modèle pour détecter des fraudes en observant des transactions de cartes sur un compte

Classification : Application 3

- Attrition
 - But : prédire si un client va probablement être perdu au profit d' un concurrent
 - Approche :
 - Utiliser les transactions des clients anciens et présents pour trouver des attributs
 - Combien de fois le client appelle, où il appelle, à quel moment de la journée il appelle le plus souvent, son statut financier, est-il marié,...
 - Étiqueter les clients comme loyaux ou déloyaux
 - Trouver un modèle de loyauté

Clustering

- Définition générale
 - Données initiales
 - Un ensemble d'objets à organiser
 - Objectifs
 - Organiser l'ensemble des objets en un ensemble de classes ou « clusters » respectant les conditions suivantes
 - La similarité entre deux objets ou individus appartenant à une même classe doit être importante
 - La similarité entre deux objets ou individus appartenant à des classes différentes doit par contre être faible
 - Remarque
 - Par rapport à un processus de classification, les classes sont à découvrir automatiquement

Clustering : Application 1

- Clustering de documents
 - But : trouver des groupes de documents similaires en se basant sur les termes qui apparaissent dans ces documents
 - Approche : identifier les termes qui apparaissent fréquemment dans chaque document. Trouver une mesure de similarité basée sur les fréquences des différents termes. L'utiliser pour faire le clustering.
 - Gain : la recherche d'informations peut utiliser les clusters pour les relier à un nouveau document ou à un terme de recherche

Applications

- Dans le domaine du marketing ou e-commerce
 - Déterminer des groupes d'individus de même profil pour le ciblage des campagnes publicitaires
- Dans le domaine des bases de données documentaires
 - Déterminer des groupes de textes comparables par leur sujets
- Dans le domaine de l'analyse d'images satellites
 - Identifier des zones urbaines ou agraires de mêmes caractéristiques

Découverte de règles d'association : définition

- Etant donné :
 - Un ensemble de transactions
 - Chaque transaction contient un ensemble d'items
- But
 - Découvrir des règles qui vont prédire la présence d'un item en se basant sur la présence d'autres dans la transaction
- Règle d'association : Implication de la forme: $X \Rightarrow Y$
«les transactions de r qui contiennent les articles de X *tendent* à contenir également les articles de Y »
- Caractérisée par 2 mesures :

Règles d'association

- **Support** (s): $\text{Sup}(X \Rightarrow Y) = p(X \cup Y) = \text{Sup}(X \cup Y) = |X \& Y|/|BD|$
« $s\%$ des transactions contiennent les articles de $X \cup Y$ »
- **Confiance** (c): $\text{Conf}(X \Rightarrow Y) = p(Y|X) = p(X \cup Y)/p(X)$
$$= \text{Sup}(X \cup Y)/\text{Sup}(X)$$

« $c\%$ des transactions qui contiennent les articles de X contiennent également les articles de Y »
- Note
 - Les règles doivent avoir un support suffisant ($> \text{minsup}$) et une confiance suffisante ($> \text{minconf}$)

Découverte de règles d'association :

Application

- Marketing et promotion
 - Soit la règle découverte
 - Pain, ... $\Rightarrow$ Lait
 - Lait comme conséquence $\Rightarrow$ comment faire pour une relance des ventes de Lait?
 - Pain comme antécédent $\Rightarrow$ quels produits seraient affectés si on annulait les ventes de pain?
 - Pain comme antécédent et Lait comme conséquence $\Rightarrow$ quels produits devraient être vendus avec le pain pour promouvoir la vente de Lait?

TID	Items
1	Pain, Lait, Beurre
2	Pain, Lait, Sucre
3	Pain
4	Pain, Lait
5	Pain, Lait, Beurre, Sucre

Découverte de motifs séquentiels

- Peut être vue comme une extension des règles d'associations intégrant diverses contraintes temporelles
- Consiste à extraire des enchaînements d'ensembles d'items couramment associés sur une période de temps bien spécifiée.
- Ex : 60% des gens qui achètent une télévision, achètent un magnétoscope dans les deux ans qui suivent
- La recherche de séquences met en évidence des associations inter-transactions, contrairement aux règles d'associations qui extraient des combinaisons intra-transactions

Deviation / Anomaly Detection

- Découverte de changements les plus significatifs dans les données à partir de celles déjà mesurées ou à partir de normes
- Détection de déviations significatives du comportement normal
- Applications
 - Détection de fraudes dans les cartes de crédit
 - Détection d'intrusion dans un réseau

Post-traitement sur les résultats

- Présentation des connaissances extraites
- Visualisation des connaissances extraites
- Manipulation des connaissances extraites


Présentation des connaissances

- Question posée
 - Comment représenter / visualiser les connaissances extraites?
- Différentes solutions
 - Formules logiques
 - $Age(X, 'young'), Income(X, 'high') \rightarrow class(X, 'A')$ [1.402]
 - $Age(X, 'young'), Income(X, 'low') \rightarrow class(X, 'B')$ [1.023]
 - $Age(X, 'old') \rightarrow class(X, 'C')$ [2.160]
 - Tableau

Age	Income	class	Count
young	high	A	1.402
young	low	B	1.023
old	high	C	0.786
old	low	C	1.374

Présentation des connaissances

- Autres solutions
 - Formules logiques
 - $Age(X, 'young'), Income(X, 'high') \rightarrow class(X, 'A') [1.402]$
 - $Age(X, 'young'), Income(X, 'low') \rightarrow class(X, 'B') [1.023]$
 - $Age(X, 'old') \rightarrow class(X, 'C') [2.160]$
 - Arbres de décision




Présentation des connaissances

- Sous forme de graphes
 - Exemple

"Products 66 & 65 are linked to high income."

"Product 67 is associated with low income and high activity."

"Product 88 is strongly connected to medium income, and to a lesser extent to low income."



Problèmes et perspectives

- Problèmes de performance
 - Les volumes de données à traiter peuvent être très importants
 - En ligne et en colonne
- Solutions
 - Techniques intelligentes et efficaces
 - Techniques incrémentales
 - Comment utiliser les résultats de calculs antérieurs pour optimiser les calculs de nouvelles requêtes d'extraction?
 - Comment stocker efficacement les résultats de requêtes d'extraction?

Problèmes et perspectives

- Besoin de langages de requêtes d' extraction
 - Exemple de limite de SQL
 - Comment répondre à la requête « Quels sont les ensembles d' articles qui ont tendance à être achetés ensemble ? »
 - Problèmes posés
 - Non réaliste de considérer tous les groupes d' articles possibles et de compter le nombre de fois qu' ils ont été achetés ensemble
 - Pas de requête simple, indépendamment de la notion « floue » de « tendance à »
 - Comment mesurer la notion floue de « tendance à »?

Langages de requêtes

- MSQL
 - T. Imienlinski and A. Virmani, « MSQL : a query language for Database Mining », Data Mining and Knowledge Discovery journal, vol.3, pp. 273-408, 1999
- MINE-RULE
 - R. Meo and G. Psaila and S. Ceri, « An extension to SQL for mining association rules », Data Mining and Knowledge Discovery journal, vol.9, pp. 207-300, 1997
- DMQL
 - J. Han and Y. Fu and W. Wang and K. Koperski and O. Zaiane, « DMQL : a data mining query language for relational databases », SIGMOD, Workshop DMKD, pp. 27-34, 1996

Langages de requêtes

- Caractéristiques principales
 - Syntaxes proches de SQL
 - Sélection (WHERE), interrogation (FROM) et manipulation des données
 - Spécification du type de motif à extraire
 - Seulement prévu par DMQL (MINE ASSOCIATION)
 - Spécification de contraintes sur les motifs à extraire
 - Support, confiance, contraintes syntaxiques
 - Manipulation des connaissances extraites et croisement avec les données de départ
 - Prévu seulement par MSQL (SELECTRULES, VIOLATES)
- Problème posé
 - Malgré quelques tentatives, pas de théorie générale et/ou algèbre