

Td Data Mining Règles d'association

Exercice 1

On considère la base de données transactionnelle suivante :

Tid	Items
T100	I1, I2, I5
T200	I2, I4
T300	I2, I3
T400	I1, I2, I4
T500	I1, I3
T600	I2, I3
T700	I1, I3
T800	I1, I2, I3, I5
T900	I1, I2, I3


- Construire le treillis complet de tous les candidats possibles. En supposant que le seuil minimal de support est de $2/9$, mettre une étiquette sur chaque nœud en utilisant les lettres suivantes :
 - NC si l'itemset n'est pas considéré comme candidat par l'algorithme Apriori ;
 - F si l'itemset est fréquent ;
 - NF si l'itemset candidat est trouvé non fréquent après le calcul du support.
 En déduire l'ensemble des itemsets fréquents.
- Un itemset fréquent est dit maximal si aucun de ses sur-ensembles immédiats n'est fréquent. Un itemset est dit fermé si aucun de ses sur-ensembles immédiats n'a le même support que lui. Trouver l'ensemble des maximaux et celui des fermés.
- Considérons l'itemset fréquent $l = \{I1, I2, I5\}$. En supposant que le seuil minimal de confiance est de 70%, quelles sont les règles intéressantes obtenues à partir de l ?

Exercice 2

On dispose des 15 itemsets candidats suivants de taille 3 qu'on veut garder dans un arbre de hachage : {145}, {124}, {457}, {125}, {458}, {159}, {136}, {234}, {567}, {345}, {356}, {357}, {689}, {367}, {368}

Après avoir rappelé la méthode de construction de l'arbre de hachage, réaliser ce dernier en montrant les différentes étapes avec :

- La fonction de hachage définie ci-contre ;
- $N=3$, où N est le nombre maximal de candidats dans une feuille ;



Exercice 3

On considère la relation Entreprise donnée ci-dessous et définie sur les attributs Dept, Statut, C_age, C_sal, Nbre. Un n-uplet (d, st, c_a, c_s, k) dans Entreprise signifie que dans le département d, il y a k employés dont le statut est st, dont l'âge est dans l'intervalle c_a et dont la catégorie du salaire est c_s.

Par exemple, la première ligne de la relation Entreprise signifie que dans le département ventes, il y a 5 employés seniors, dont l'âge est compris entre 31 et 35 ans et dont le salaire est haut.

<i>Dept</i>	<i>Statut</i>	<i>C_age</i>	<i>C_sal</i>	<i>Nbre</i>
Vente	senior	31-35	Haut	5
Vente	junior	26-30	Bas	3
Vente	junior	21-25	Bas	6
Fabrication	junior	21-25	Haut	10
Fabrication	senior	31-35	Haut	15
Fabrication	junior	26-30	Haut	5
Fabrication	senior	41-45	Haut	3
Marketing	senior	36-40	Haut	8
Marketing	junior	31-35	Moyen	15
Secrétariat	senior	46-50	Moyen	2
Secrétariat	junior	26-30	Bas	5

Entreprise

Considérons les données de la projection sur les attributs Dept and C_age de la relation Entreprise. On s'intéresse maintenant à la découverte de règles d'association entre les valeurs de l'attribut C_age pour les employés du même département.

Par exemple, la règle d'association $26-30 \Rightarrow 41-45$ signifie que si un département d a un employé dont l'âge est compris entre 26 et 30 ans, alors ce département d tend à avoir également un employé dont l'âge est compris entre 41 et 45 ans.

1. Appliquer l'algorithme APRIORI avec un support minimum de 50%, pour trouver les motifs intéressants d'intervalles d'âge.
2. Trouver toutes les règles exactes (i.e., règles avec une confiance égale à 1) dont le support est supérieur ou égal à 50%. Existe-t-il d'autres règles exactes? Si oui, donner un exemple d'une telle règle.